## Andrii Prykhodko FB31mp Lab1

На основі будь-якого access.log сформувати датасет, що надав би інформацію про

користувачів веб-ресурсу, а потім виконати наступні кроки:

- 1.Визначити кількість користувачів за днями
- 2.Ранжувати користувачів за User-Agent
- 3. Ранжувати користувачів за операційними системами
- 4. Ранжувати користувачів за країною запиту
- 5. Виокремити пошукових ботів
- 6.Детектувати аномалії (якщо такі є)

Source <a href="https://github.com/andriiprykhodko96/web\_anal/blob/main/lab1/lab1.ipynb">https://github.com/andriiprykhodko96/web\_anal/blob/main/lab1/lab1.ipynb</a>

#### Отримали датасет:

ut[5]:		IP Address	Timestamp	HTTP Method	HTTP Status	User Agent
	0	1.202.218.8	[20/Jun/2012:19:05:12 +0200]	"GET	HTTP/1.0"	"\"Mozilla/5.0"
	1	208.115.113.91	[20/Jun/2012:19:20:16 +0200]	"GET	HTTP/1.1"	"Mozilla/5.0 (compatible; Ezooms/1.0; ezooms.b
	2	123.125.71.20	[20/Jun/2012:19:30:40 +0200]	"GET	HTTP/1.1"	"Mozilla/5.0 (compatible; Baiduspider/2.0; +ht
	3	220.181.108.101	[20/Jun/2012:19:31:01 +0200]	"GET	HTTP/1.1"	"Mozilla/5.0 (compatible; Baiduspider/2.0; +ht
	4	123.125.68.79	[20/Jun/2012:19:53:24 +0200]	"GET	HTTP/1.1"	"Mozilla/5.0 (compatible; Baiduspider/2.0; +ht

#### Кількість запитів по даті:

```
In [6]:
             df['Timestamp'] = pd.to\_datetime(df['Timestamp'], \ format='[%d/%b/%Y:%H:%M:%S %z]') \\ df['Date'] = df['Timestamp'].dt.date 
In [7]: user_count_per_day = df.groupby('Date')['IP Address'].nunique()
    print(user_count_per_day)
          Date
2012-06-20
          2012-06-21
2012-06-22
2012-06-23
                             68
                             83
          2012-06-24
                             78
          2012-06-25
                             73
          2012-06-26
2012-06-27
                             90
73
          2012-06-28
          2012-06-29
                             93
          2012-06-30
2012-07-01
                             82
          2012-07-02
          Name: IP Address, dtype: int64
```

#### Основано на User Agent:

## Спроба дістати операційну систему:

```
In [9]:
    def extract_operating_system(user_agent):
        match = re.search(r'\(([^\)]+\))', user_agent)
        if match:
            info = match.group(1)
            os_info = info.split(';')[0]
            return os_info.strip()
        else:
                return 'Unknown'

    df['Operating System'] = df['User Agent'].apply(extract_operating_system)

# Group the dataset by the operating system and count occurrences
    operating_system_counts = df.groupby('Operating System').size().reset_index(name='Count')

# Sort the grouped dataset in descending order based on the count of occurrences
    sorted_operating_systems = operating_system_counts.sort_values('Count', ascending=False)

# Print the result
    print(sorted_operating_systems)
```

```
Operating System
20
                                                compatible
                                                              1572
                                                  Unknown
                                           Windows NT 6.1
Windows NT 5.1
16
14
18
                                                                 21
                                           bot@wotbox.com
13
                                                   Windows
                                                                 17
               +http://www.baidu.com/search/spider.htm
Windows NT 6.0
3
15
                                                                 17
                                                                 17
                              +http://fulltext.sblog.cz/
25
                                          www.aghaven.com
                                                                 16
              http://www.backlinktest.com/crawler.html
22
                                                                 16
             +http://www.google.com/mobile/adsbot.html
2
21
         +http://wortschatz.uni-leipzig.de/findlinks/
                                                                 12
                       http://www.aboundex.com/crawler/
                                                                 11
26
                              www.metadatalabs.com/mlbot
                                                                 10
17
                                                     Linux
                                                                 8
    +http://www.sogou.com/docs/help/webmasters.htm#07
                     +http://www.google.com/adsbot.html
19
                                 cboc-test@lab.ntt.co.jp
                                                    Ubuntu
11
10
                                                 Macintosh
                                                                 3
            http://www.fybersearch.com/fyberspider.php
+http://code.google.com/appengine
23
                                        KHTML, like Gecko
                                                        GUT
                                                                  1
                                                     iPhone
24
                                                                 1
```

### Фільтр для ботів, фільтруємо Bing, Google and Yandex are out ;)

```
bot_pattern = r'(Googlebot|Bingbot|YandexBot)'
bot_df = df[df['User Agent'].str.contains(bot_pattern, regex=True)]
   print(bot_df)
                                                               IP Address
          178.154.210.252 2012-06-20 19:54:10+02:00
               66.249.72.65 2012-06-20 21:28:00+02:00 66.249.72.65 2012-06-20 21:28:00+02:00
                                                                                            "GET
                                                                                                        HTTP/1.1"
15
         178.154.210.252 2012-06-20 21:45:12+02:00 66.249.72.65 2012-06-21 05:59:24+02:00
                                                                                                       HTTP/1.1"
HTTP/1.1"
18
                                                                                            "GET
                                                                                            "GET
84
2080
                                                                                            "GET
             66.249.66.140 2012-07-02 02:05:49+02:00
        66.249.66.140 2012-07-02 02:05:49+02:00
66.249.66.1 2012-07-02 03:47:36+02:00
178.154.210.252 2012-07-02 07:20:22+02:00
                                                                                            "GET
                                                                                                       HTTP/1.1"
2085
                                                                                            "GET HTTP/1.1"
"GET HTTP/1.1"
2097 178.154.210.252 2012-07-02 07:20:24+02:00
                                                                                                         Date \
                                                                           User Agent
         "Mozilla/5.0 (compatible; YandexBot/3.0; +http... 2012-06-20
"Mozilla/5.0 (compatible; Googlebot/2.1; +http... 2012-06-20
"Mozilla/5.0 (compatible; Googlebot/2.1; +http... 2012-06-20
"Mozilla/5.0 (compatible; YandexBot/3.0; +http... 2012-06-20
"Mozilla/5.0 (compatible; YandexBot/3.0; +http... 2012-06-20
14
15
          "Mozilla/5.0 (compatible; Googlebot/2.1; +http... 2012-06-21
84
2080 "Mozilla/5.0 (compatible; Googlebot/2.1; +http... 2012-07-02
2081 "Mozilla/5.0 (compatible; Googlebot/2.1; +http... 2012-07-02
2085 "Mozilla/5.0 (compatible; Googlebot/2.1; +http... 2012-07-02
2096 "Mozilla/5.0 (compatible; YandexBot/3.0; +http... 2012-07-02
2097 "Mozilla/5.0 (compatible; YandexBot/3.0; +http... 2012-07-02
        Operating System
                  compatible
                  compatible
14
                  compatible compatible
15
 18
84
                  compatible
2080
                  compatible
2081
                  compatible
2085
                  compatible
2096
                  compatible
                  compatible
[406 rows x 7 columns]
```

# Один з прикладів можливих аномалій - кількість запитів з одного ІР. На графіку поставлено топ 20

```
in [11]:
    ip_counts = df['IP Address'].value_counts().head(20)

# Plot the IP address distributions
plt.figure(figsize=(10, 6))
    ip_counts.plot(kind='bar')
plt.xlabel('IP Address')
plt.ylabel('Gount')
plt.title('IP Address Distributions')
plt.xticks(rotation=45)
plt.show()
```

